

pyscenic 脚本使用文档

1. 简介


SCENIC是2017年11月发表在Nature Methods 期刊的一种单细胞转录因子分析方法，也是目前进行单细胞转录因子分析的主流软件，该软件在进行数据分析的同时也能得到可视化结果图。该软件是有物种限制的，目前只能分析人、小鼠和果蝇的数据。

2. 原理

SCENIC经过以下三个步骤完成转录因子分析：第一步是构建共表达网络、第二步是构建TF-targets网络、第三步是计算Regulons活性，每一个步骤都由一个专门的软件包完成。

2.1 GENIE3—共表达网络构建


GENIE3 (GEne NetworkInference with Ensemble of trees)，基于树的基因网络推理，是一种从基因表达数据推断基因调控网络的方法。软件以单细胞基因表达量矩阵为输入文件，以每个目标基因（gene）为输出，以转录因子（TF）为输入，构建P个随机森林树（P=矩阵中基因数量），并计算每个TF与gene之间的重要性评分（IM），最终可以获得TF-genes共表达模块。最后删除IM低于阈值的基因关系，过滤基因数低于50的模块。



2.2 RcisTarget—motif富集及靶基因预测

这一步可以借助RcisTarget软件完成，该软件运行必备两个数据库：1) gene-motif排名数据库：为每个motif提供所有gene的排名（~分数）；2) motif-TF注释数据库：对每一个motif注释其所对应的TF。由于不同物种基因组不一样，导致每个motif对应靶基因不同，因此针对不同物种需要构建不同的数据库，软件目前配置了人、小鼠、果蝇数据库。首先基于gene-motif数据库，每个motif对模块中所有基因进行累积，模块中的基因排名越靠前，累积曲线越高，曲线下面积（AUC）越大，表明motif在该模块中的富集程度越高，然后对

每个模块选取显著富集的motif，并预测其靶基因，最终综合TF-genes模块和靶基因预测结果，构成一个包含了TF和靶基因的基因调控网络模块（regulons）。




2.3 AUCell—Regulons活性定量

第三步就是Regulons活性定量。这一步由AUCell软件完成，AUCell是一种新的方法，允许在scRNA-seq数据中识别具有活性基因调控网络的细胞。

实际分析过程中，输入到AUCell的是一个基因集，输出的是每个细胞中的基因集“活性”（AUC，Area Under Curve）[2]。在SCENIC中，这些基因集即Regulons中所有基因，针对每个细胞，将细胞中所有基因按照表达量从高到低进行排序，根据Regulons中的基因在序列中的位置，计算累计曲线面积（AUC），即为Regulons在细胞中的活性。

但由于不同regulons包含的基因不同，它们之间的AUC值不具有可比较性，因此基于AUC值在所有细胞中的双峰分布特征，增加了Regulons“on/off”的概念，认为双峰之间的低谷为判断Regulons活性开放的阈值，如果AUC值小于阈值，则判定为该Regulons在该细胞中未开放，即未发挥调控作用。最终获得每个Regulons在每个细胞中的开放性热图。



3. 使用方法

3.1 准备数据

- rds: 原始单细胞数据rds
- tfs: 文本文件, 每行一个基因名, 包括所有要考虑的转录因子
- feather: cisTarget数据库的feather格式文件
- tbl: cisTarget数据库的motif注释文件

3.2 运行流程

- 数据过滤
 - 使用R脚本data.r, 根据percentage参数对表达矩阵进行过滤
 - 保存过滤后矩阵到file_data_outdir目录
- 格式转换
 - 使用change.py将过滤后的loom矩阵转换为pyscenic支持的格式
 - change.py无需参数, 直接运行
- GRN构建
 - 使用pyscenic grn, 采用grnboost2方法构建调控网络
 - 保存结果到grn_result.csv
- cisTarget注释
 - 使用pyscenic ctx, 采用feather和tbl对网络进行注释

- 保存结果到ctx.csv
- AUCell计算
 - 使用pyscenic aucell, 基于ctx结果计算单细胞的激活状态
 - 保存结果到out_SCENIC.loom

3.3 参数配置

- input_path:原始loom矩阵路径
- percentage:过滤比例, 0-1之间
- file_data_outdir:过滤后数据输出目录
- result_dir:结果文件目录
- feather:feather文件路径
- tbl:tbl文件路径
- tfs:转录因子列表路径
- num_workers:进程数, 并行计算的进程数

3.4 结果文件

- grn_result.csv:节点为基因, 边为调控关系
- ctx.csv:对网络调控关系进行转录因子注释
- out_SCENIC.loom:最终输出结果, 用来做后续的可视化分析